

臺北房屋買賣資料分析

組名：Duke Lasagna

組員：資訊系 115 白淳文

資訊系 115 張亦辰

資訊系 115 顏辰旭

報告影片連結：

<https://www.youtube.com/watch?v=Vo2ai-fxOpc>

一、背景動機

擁有一棟屬於自己的房子是許多人的夢想，因為這對生活品質和財務決策有著深遠的影響。然而，在台北高昂的房價下，了解影響房價的因素變得尤為重要。這不僅能幫助潛在的買家評估房屋是否物有所值，也能協助賣家制定合理的售價，從而促進房地產市場的良性交易。無論是在個人層面的購房或投資決策，還是在商業層面的地產中介與開發商的市場評估中，這些洞察都有廣泛的應用價值。我們想利用課堂所學運用於臺北房屋買賣資料分析，結合臺北房屋買賣資料進行分析，以預測房價並探討影響其變化的關鍵因素，為相關決策提供更具參考價值的依據。

二、資料集簡述

這次資料分析所使用的資料原計畫是以爬蟲爬取內政部不動產交易時價查詢服務網之資料，但由於後來發現該網站似乎設有阻擋爬蟲之機制，於是我們改為爬取臺北市不動產實價周報開放資料，並利用API位址、API使用方式與參數來發送請求，進而爬取回應的不動產實價資料。

詳細資料

API位址	https://data.taipei/api/v1/dataset/2979c431-7a32-4067-9af2-e716cd825c4b?scope=resourceAquire
異動時間	2025-01-08 09:13:23
API使用方式	GET
參數	{ "resource_id": "2979c431-7a32-4067-9af2-e716cd825c4b" }

參數名稱	類型	描述
q	string	關鍵字查詢
limit	int	筆數上限(1000)
offset	int	位移筆數

關閉

成交案件類型(CASE_T)、行政區(DISTRICT)、交易標的/租賃標的(CASE_F)、預售屋建案名稱(BUILD_NAME)、土地區段位置或建物區門牌(LOCATION)、土地移轉總面

(附圖：臺北市不動產實價周報開放資料API相關資訊)

該資料集所包含數據特徵有：

成交案件類型 (CASE_T)、行政區 (DISTRICT)、交易標的/租賃標的 (CASE_F)、預售屋建案名稱 (BUILD_NAME)、土地區段位置或建物區門牌 (LOCATION)、土地移轉總面積 (坪)/土地租賃總面積 (坪) (LANDA)、都市土地使用分區 (LANDA_Z)、交易年月 (SDATE)、交易筆棟數/租賃筆棟數 (SCNT)、預售屋交易標的 (TRANS_TARGET)、移轉層次 (SBUILD)、總樓層數 (TBUILD)、建物型態 (BUITYPE)、主要用途 (PBUILD)、主要建材 (MBUILD)、建築完成年月 (FDATE)、建物移轉總面積 (坪)/租賃總面積 (坪) (FAREA)、建物現況格局_房 (BUILD_R)、建物現況格局_廳 (BUILD_L)、建物現況格局_衛 (BUILD_B)、建物現況格局_隔間 (BUILD_

P)、有無管理組織 (RULE)、有無附傢俱 (BUILD_C)、交易總價 (萬元) / 租賃總價 (萬元) (TPRICE)、交易單價 (萬元/坪) / 租賃單價 (元/坪) (UPRICE)、單價是否含車位 (UPNOTE)、車位類別及數量 (PARKTYPE)、車位移轉總面積 (坪) / 車位租賃總面積 (坪) (PAREA)、車位移轉總價 (萬元) / 車位租賃總價 (元) (PPRICE)、有無電梯 (ELEVATOR)、主建物總面積 (MB_AREA)、附屬建物總面積 (SB_AREA)、共有部分總面積 (PU_AREA)、備註 (RMNOTE)。

在擷取臺北市不動產實價周報開放資料所提供的API資料後即可引用requests模組，並使Python網頁爬蟲發送請求到臺北市不動產實價周報的開放資料API，並且傳入必要的參數，最後將Python網頁爬蟲取得的回應結果經過編譯法處理，轉為utf-8已呈現中文資料後即可轉存為csv檔資料形式進行接下來的資料分析。

```
import requests
import pandas as pd

params = {
    "resource_id": "2979c431-7a32-4067-9af2-e716cd825c4b",
    "limit": 1000
}

response = requests.get("https://data.taipei/api/v1/dataset/2979c431-7a32-4067-9af2-e716cd825c4b?scope=resourceAquire", params=params)

# Ensure the response encoding is set to UTF-8
response.encoding = 'utf-8'

data = response.json()['result']['results']

df = pd.DataFrame(data)
# Save the DataFrame to a CSV file with UTF-8 encoding
df.to_csv('output.csv', index=False, encoding='utf-8-sig')
```

(附圖：Python 不動產爬蟲程式碼)

```
la,landa_z,sdate,scnt,trans_target,sbuild,tbuild,builttype,pbuild,mbuild,fdate,farea,build_r,build_l,build_b,build_p,rule,build_c,tprice,uprice,upnote,
timezone': 'Asia/Taipei'))",租賃,士林區,房屋,,中山北路五段699巷12號,0,,1131105,土地:建物:車位:,,二層,002,透天厝,住家用,,4.5,3,0,3,有,無,有,1,0,,0,0,,
timezone': 'Asia/Taipei'))",買賣,中正區,房地(土地+建物)+車位,,漢口街一段57號十四樓之5,2.39,,1130918,土地:1建物:1車位:1,,十四層,,大樓(11層含以上有電梯),見其他
timezone': 'Asia/Taipei'))",租賃,大安區,房屋,,泰順街54巷6號二樓,0,,1131106,土地:建物:1車位:,,二層,005,公寓(無電梯),住家用,,38.22,4,2,2,有,無,無,4,915.75,
timezone': 'Asia/Taipei'))",買賣,中山區,房地(土地+建物)+車位,,敬業三路162巷57號七樓,14.24,,1130913,土地:1建物:1車位:1,,七層,,華廈(10層含以下有電梯),住家用,,
timezone': 'Asia/Taipei'))",租賃,大安區,房屋,,信義路三段147巷17弄17號四樓之2,0,,1131101,土地:建物:1車位:,,四層,007,華廈(10層含以下有電梯),住家用,,8.35,1,1,
timezone': 'Asia/Taipei'))",租賃,萬華區,房屋,,德昌街147巷9號四樓,0,,1131106,土地:建物:1車位:,,四層,005,公寓(無電梯),住家用,,28.3,2,1,有,無,無,2,535.71,否,
timezone': 'Asia/Taipei'))",買賣,大安區,土地,,通化段六小段0344-0000地號,0.97,,1131106,土地:1建物:0車位:,,,,,,,0,,無,無,,142,146.39,,0,0,無,,
timezone': 'Asia/Taipei'))",租賃,中山區,房屋,,吉林路393巷19號四樓,8.77,,1131104,土地:1建物:1車位:,,四層,004,公寓(無電梯),住家用,,24.3,3,2,2,有,無,無,3,135
timezone': 'Asia/Taipei'))",買賣,中正區,房地(土地+建物),,中華路二段309巷16號三樓,4.46,,1131101,土地:1建物:1車位:,,三層,,公寓(5樓含以下無電梯),,,10.62,1,1,
timezone': 'Asia/Taipei'))",買賣,士林區,房地(土地+建物),,承德路四段294號六樓,5.83,,1131027,土地:1建物:1車位:,,六層,,大樓(11層含以上有電梯),住家用,,43.7,4,
timezone': 'Asia/Taipei'))",預售屋,信義區,房地(土地+建物)+車位,,徽信義,臺北市信義區基隆路二段64~72號,0.89,,1131107,土地:5建物:1車位:1,0棟C號,十四層,015,住宅
timezone': 'Asia/Taipei'))",買賣,信義區,房地(土地+建物)+車位,,信義路五段91巷12弄1號六樓之8,4.97,,1131119,土地:1建物:1車位:1,,一層,地下一層,地下二層,地下三/
timezone': 'Asia/Taipei'))",買賣,松山區,房地(土地+建物),,復興北路361巷18號七樓,6.66,,1131028,土地:1建物:1車位:,,七層,,華廈(10層含以下有電梯),住家用,,39.06
timezone': 'Asia/Taipei'))",預售屋,中正區,房地(土地+建物),,南陽龍路,臺北市中正區黎明里南陽街,2.1,,1130802,土地:8建物:1車位:1,0棟C號,九層,012,住宅大樓(11層含
timezone': 'Asia/Taipei'))",買賣,士林區,土地,,溪洲段二小段0202-0001地號,776.42,,1130807,土地:1建物:0車位:,,,,,,,0,,無,無,,20963,27,,0,0,無,,
timezone': 'Asia/Taipei'))",買賣,松山區,房地(土地+建物),,八德路四段8號六樓,8.78,,1130818,土地:1建物:1車位:,,六層,,華廈(10層含以下有電梯),住家用,,51.24,4,2
timezone': 'Asia/Taipei'))",買賣,內湖區,房地(土地+建物)+車位,,南京東路六段451巷57號四樓,4.88,,1130929,土地:1建物:1車位:1,,四層,,大樓(11層含以上有電梯),商業
timezone': 'Asia/Taipei'))",買賣,萬華區,房地(土地+建物),,國興路1巷5號九樓之1,8.18,,1131024,土地:1建物:1車位:,,九層,,大樓(11層含以上有電梯),住家用,,30.78,2
timezone': 'Asia/Taipei'))",預售屋,大安區,房地(土地+建物)+車位,,龍邦豐盛,臺北市大安區浦城街15-19號,6.46,,1131101,土地:2建物:1車位:1,0棟3F-A2號,三層,008,華
timezone': 'Asia/Taipei'))",買賣,中正區,房地(土地+建物),,羅斯福路三段100之57號,0.3,,1131023,土地:4建物:1車位:,,一層,,大樓(11層含以上有電梯),商業用,,1.96,1
timezone': 'Asia/Taipei'))",租賃,北投區,房屋,,明德路121號一樓,11.57,,1131107,土地:1建物:1車位:,,一層,004,店面(店舖),住家用,,35.55,,有,無,無,7,2025.32,
timezone': 'Asia/Taipei'))",買賣,內湖區,房地(土地+建物)+車位,,內湖路一段91巷83號五樓,6.63,,1130927,土地:1建物:1車位:1,,五層,,華廈(10層含以下有電梯),見其他
timezone': 'Asia/Taipei'))",預售屋,萬華區,房地(土地+建物)+車位,,龍邦豐盛,臺北市萬華區西園路二段,5.26,,1131103,土地:34建物:1車位:1,1棟B3-10F號,十層,015,住宅
timezone': 'Asia/Taipei'))",租賃,北投區,房屋,,明德路335巷20號二樓,0,,1131107,土地:建物:1車位:,,二層,004,公寓(無電梯),住家用,,31.08,3,2,2,有,無,有,3,1093.
timezone': 'Asia/Taipei'))",租賃,萬華區,房屋,,萬大路618巷35號,0,,1131107,土地:建物:1車位:,,一層,003,公寓(無電梯),,,18.5,1,2,1,有,無,有,2,1081.08,否,0,0
timezone': 'Asia/Taipei'))",預售屋,中正區,房地(土地+建物),,南陽龍路,臺北市中正區黎明里南陽街,2.1,,1130812,土地:8建物:1車位:1,0棟C號,十層,012,住宅大樓(11層含
timezone': 'Asia/Taipei'))",虎林街232巷15之1號,2.63,,1131114,土地:1建物:1車位:,,二層,,公寓(5樓含以下無電梯),住家用,,6.46,3,2
timezone': 'Asia/Taipei'))",買賣,士林區,房地(土地+建物),,中山北路七段82巷15號二樓,10.89,,1130812,土地:1建物:1車位:,,二層,,公寓(5樓含以下無電梯),住家用,,34
timezone': 'Asia/Taipei'))",預售屋,松山區,房地(土地+建物)+車位,,鳴森苑,臺北市松山區延壽街,5.97,,1131102,土地:1建物:1車位:1,0棟02-11C號,十一層,031,住宅大樓(11
```

(附圖：爬取資料集檢視)

在爬到不動產資料之後，我們接著到[台灣電子地圖服務](#)來爬取各房屋之位置經緯度以及[台北市捷運路網圖、各站資訊](#)來爬取各站位置，以方便計算各房屋周邊有多少捷運站。但因為[台灣電子地圖服務](#)的網站會偵測爬蟲行為，因此我們後續就用[Google 地球](#)來進行地址->經緯度換算，以取得兩地之絕對距離。

```
# 啟動瀏覽器
browser = webdriver.Chrome(service=service, options=options)
browser.get("https://www.metro.taipei/cp.aspx?n=91974F2B13D997F1")
time.sleep(0.1)
iframe = browser.find_element(By.ID, "route")
browser.switch_to.frame(iframe)
select = browser.find_element(By.ID, "menulistsingle")

# 使用 Select 類處理下拉選單

select_obj = Select(select)
# 列出所有選項
select_list = []
for option in select_obj.options:
    print(f"Value: {option.get_attribute('value')}, Text: {option.text}")
    select_list.append(option.get_attribute('value'))
# print(len(select_obj.options))
```

(附圖：Python 捷運爬蟲程式碼)

三、資料前處理

由於所抓取的資料大於我們預期分析的資料範圍，我們先將年份、交易型態不符的資料刪除，後針對特徵進行初步篩選與整理——刪除不必要欄位、缺失值過多欄位，或是包含異常值的欄位，並且以中位數補足少許缺失的數值型資料欄。最為重要的是，資料集中包含以目標特徵（即總價）為基礎計算獲得的相關特徵，包括單位面積價格、車位價格等等，這種Target leakage將導致模型結果極佳，卻不切實際，因為間接使用到了本該未知的預測目標，因此也在起初就刪除相關欄位。至此，資料集已剩19種特徵，並儲存為“cleaned_data”供後續模型使用。

接著，我們依照所選擇的三種模型對應特性，以不同的方式處理類別型特徵。其中，有些能被二元分類，就用Label encoding作區分；其他種類較多、無法簡單區分的在以下列點分別介紹。

1. Ridge Regression

Ridge Regression對於多重共線性較為敏感，預處理時需確保資料集維持在適當大小，並避免冗餘的維度。而Target encoding保留了與目標變數的相關性，同時避免引入高維度問題，是合適Ridge的編碼方式，因此我們將剩餘類別型資料都經過Target encoding後進行特徵選擇。

同樣的，Ridge Regression進行特徵選擇時，重點也在於處理多重共線性對模型的影響。我們以相關係數作為指標，分析數據中特徵與目標變數之間的相關性，並將結果以長條圖視覺化（圖表呈現於「五、結果分析」），篩選、保留高相關（絕對值大於0.3）的特徵。

```

one_hot_columns = []
label_columns = ['case_t', 'build_p', 'rule', 'upnote', 'elevator', 'buitype']
target_columns = ['pbuild', 'district', 'case_f', 'sbuild']
numeric_features = df.select_dtypes(include=['float64', 'int64']).columns

label_encoders = {col: LabelEncoder() for col in label_columns}

for col in label_columns:
    df[col] = label_encoders[col].fit_transform(df[col])

df = pd.get_dummies(df, columns=one_hot_columns, drop_first=True)

target_encoder = ce.TargetEncoder(cols=target_columns)
df[target_columns] = target_encoder.fit_transform(df[target_columns], df['tprice'])

```

(附圖：Ridge regression 編碼處理)

```

# Step 1: evaluate the correlation of features
correlation_matrix = df.corr()
correlation_with_target = correlation_matrix['tprice'].drop('tprice').sort_values(ascending=False)

# Step 2: plot the feature correlation
plt.figure(figsize=(10, 10))
sns.barplot(x=correlation_with_target, y=correlation_with_target.index)
plt.title('Correlation with tprice')
plt.show()

# Step 3: select features with threshold greater than 0.3 as new dataset
correlation_threshold = 0.3
selected_features = correlation_with_target[abs(correlation_with_target) > correlation_threshold].index
X_selected = df[selected_features]
y = df['tprice']

```

(附圖：Ridge regression 特徵選擇)

2. Decision Tree

決策樹可以自然地處理分類的分割，但透過One-hot encoding可以為擁有多個不同值的類別創建更具表現力的特徵集。Target encoding則保留了有意義的關係，同時避免特徵空間過度膨脹。由於決策樹對兩種編碼方式的適應性都相當充足，我們決定混合兩種編碼方式，經過排列嘗試後，找到最佳組合並使用之。

決策樹進行特徵選擇時，主要依賴其內建的分裂機制。模型訓練後，可檢視特徵重要性分數，並將結果以長條圖視覺化（圖表呈現於「五、結果分析」），移除得分較低的

特徵，保留對性能影響較大（重要性分數高於0.01）的特徵。此外，由於決策樹能自動忽略與目標變數無關的特徵，因此對於特徵選擇的需求相對較低。

```
one_hot_columns = ['district', 'sbuild']
label_columns = ['case_t', 'build_p', 'rule', 'upnote', 'elevator', 'buitype']
target_columns = ['pbuild', 'case_f']

label_encoders = {col: LabelEncoder() for col in label_columns}

for col in label_columns:
    df[col] = label_encoders[col].fit_transform(df[col])

df = pd.get_dummies(df, columns=one_hot_columns, drop_first=True)

target_encoder = ce.TargetEncoder(cols=target_columns)
df[target_columns] = target_encoder.fit_transform(df[target_columns], df['tprice'])
```

（附圖：Decision tree 編碼處理）

```
# Step 4: evaluate the importance of features
importance = model.feature_importances_

importance_df = pd.DataFrame({
    'Feature': X.columns,
    'Importance': importance
}).sort_values(by='Importance', ascending=False)

print(importance_df)

# Step 5: plot the feature importance using Seaborn
top_features = importance_df.head(20)
plt.figure(figsize=(10, 8))
sns.barplot(
    data=top_features,
    x='Importance',
    y='Feature',
    palette='viridis'
)
plt.xlabel('特徵重要性', fontsize=12, fontweight='bold') # 加粗 x 軸標籤
plt.ylabel('特徵', fontsize=12, fontweight='bold')      # 加粗 y 軸標籤
plt.title('Top 20 XGBoost 特徵重要性', fontsize=14, fontweight='bold') # 加粗標題
plt.tight_layout()
plt.show()

# Step 6: select features with importance greater than 0.01 as new dataset
selected_features = importance_df[importance_df['Importance'] > 0.01]['Feature'].tolist()
X_selected = X[selected_features]
```

（附圖：Decision tree 特徵選擇）

3. XGBoost

XGBoost 對數值和分類特徵都非常有效。使用One-hot encoding將分類特徵展開為二進制表示形式，這與 XGBoost 的基於樹的分割機制非常契合。因此我們將剩餘類別型資料都經過One-hot encoding後進行特徵選擇。

XGBoost 進行特徵選擇時，步驟與決策樹相仿，主要依靠其內建的特徵篩選功能。模型訓練後，可檢視特徵重要性分數，並將結果以長條圖視覺化（圖表呈現於「五、結果分析」），移除得分較低的特徵，保留對性能影響較大（重要性分數高於0.01）的特徵。

```
one_hot_columns = ['pbuild', 'district', 'case_f', 'sbuild']
label_columns = ['case_t', 'build_p', 'rule', 'upnote', 'elevator', 'buitype']
target_columns = []

label_encoders = {col: LabelEncoder() for col in label_columns}

for col in label_columns:
    df[col] = label_encoders[col].fit_transform(df[col])

df = pd.get_dummies(df, columns=one_hot_columns, drop_first=True)

target_encoder = ce.TargetEncoder(cols=target_columns)
df[target_columns] = target_encoder.fit_transform(df[target_columns], df['tprice'])
```

（附圖：XGBoost 編碼處理）

```

# Step 4: evaluate the importance of features
importance = model.feature_importances_

importance_df = pd.DataFrame({
    'Feature': X.columns,
    'Importance': importance
}).sort_values(by='Importance', ascending=False)

print(importance_df)

# Step 5: plot the feature importance
top_features = importance_df.head(20)
plt.figure(figsize=(10, 8))
sns.barplot(
    data=top_features,
    y='Feature',
    x='Importance',
    palette='viridis'
)

# Step 6: select features with importance greater than 0.01 as new dataset
selected_features = importance_df[importance_df['Importance'] > 0.01]['Feature'].tolist()
X_selected = X[selected_features]

```

(附圖：XGBoost 特徵選擇)

Encoding method	Ridge regression	Decision tree	XGBoost
Label	V	V	V
Target	V	V	X
One-hot	X	V	V
Thrshold	0.3	0.01	0.01

(附圖：模型資料處理比較)

四、模型架構及參數選擇

依照原先在報告提案中規劃好的方式，我們將資料分成訓練集與測試集，比例為 8:2。過程中使用 5 折交叉驗證，通過多次訓練與測試，全面評估模型的穩定性與泛化能力。最後應用最佳模型於測試集時，以平均絕對誤差 (MAE)、均方根誤差 (RMSE)、決定係數 (R^2) 三者綜合評估模型果效。而建模方法和參數選擇則根據模型有所不同，以下列點分別介紹三種模型。

1. Ridge regression

Ridge regression 關注數據中的多重共線性，核心目的是透過 L2 正則化控制參數大小，減少模型因多重共線性導致的過度擬合問題。這種方法特別適合處理高維數據或存在多餘特徵的情況，因為它在損失函數中加入了正則化項，對大係數進行懲罰，使模型更加穩定。此外，網格搜尋與交叉驗證確保模型在多組訓練/驗證分割下都能有良好的表現，從而提升泛化能力。

```
# Step 1: Use GridSearchCV to find the best hyperparameters
ridge = Ridge()
param_grid = {
    'alpha': np.logspace(-4, 4, 10)
}
```

(附圖：Ridge regression 參數設定)

2. Decision tree

決策樹的設計目的是利用其非線性劃分能力，捕捉特徵與目標變數之間的複雜關係，能有效處理類別型與數值型特徵混合的數據。通過調整樹深度、分裂與葉節點的條件，平衡模型的表現與複雜度，避免過度擬合 (過深的樹) 或欠擬合 (過淺的樹)。其內

建特徵選擇機制可以自動識別重要特徵，進一步提高效率。此外，利用網格搜尋結合交叉驗證，確保參數調整的全面性與穩健性。

```
param_grid = {  
    'max_depth': [3, 5, 10, None],  
    'min_samples_split': [2, 5, 10],  
    'min_samples_leaf': [1, 2, 4],  
    'max_features': [None, 'sqrt', 'log2']  
}
```

(附圖：Decision tree 參數設定)

3. XGBoost

XGBoost 是一種基於梯度提升的強大模型，設計目的是通過多棵弱模型（決策樹）逐步降低預測誤差。相比於傳統的梯度提升，XGBoost 在效率與精度上都有顯著提升，例如利用列抽樣與並行計算來加速訓練過程，適合應對非線性關係複雜且包含大量特徵的數據集。超參數優化中，採用 Optuna 進行自動調參，能快速探索多維超參數空間，找到最優解。這使得模型可以適應高度非線性與高維度數據集。

```
# Step 1: optimize the hyperparameters using Optuna  
def objective(trial):  
    # Set hyperparameters to tune  
    n_estimators = trial.suggest_int('n_estimators', 50, 300)  
    max_depth = trial.suggest_int('max_depth', 3, 10)  
    learning_rate = trial.suggest_float('learning_rate', 0.01, 0.2)  
    subsample = trial.suggest_float('subsample', 0.6, 1.0)  
    colsample_bytree = trial.suggest_float('colsample_bytree', 0.6, 1.0)  
    reg_alpha = trial.suggest_float('reg_alpha', 0.0, 0.1)  
    reg_lambda = trial.suggest_float('reg_lambda', 1.0, 10.0)  
    min_child_weight = trial.suggest_int('min_child_weight', 1, 5)
```

```
# Step 2: Run Optuna optimization
study = optuna.create_study(direction='minimize')
study.optimize(objective, n_trials=50)
```


(附圖 : XGBoost 參數設定)

五、結果分析


模型訓練後，我們將其套用到驗證集上（原始資料以8:2切分），其中Linear Regression的Rsquared分數為0.861，Decision Tree的分數為0.862，XGBoost的分數為0.8791 ± 0.0349，顯示這些房屋資料都能成功預測房價高低。

接下來，我們會以可解釋性的角度說明各個特徵，來讓使用者了解那些特徵對房價是較為重要的。


1. 結果展示



在所有特徵中，Linear Regression認為比較重要的前五個特徵分別是建物移轉總面積（坪）/租賃總面積（坪）（FAREA）、交易標的/租賃標的（CASE_F）、車位移轉總面積（坪）/車位租賃總面積（坪）（PAREA）、成交案件類型（CASE_T）、移轉層次（SBUILD）。



在所有特徵中，DecisionTree認為比較重要的前五個特徵分別是建物移轉總面積（坪）/租賃總面積（坪）（FAREA）、區域、車位移轉總面積（坪）/車位租賃總面積（坪）（PAREA）、有無電梯（ELEVATOR）、土地移轉總面積（坪）/土地租賃總面積（坪）（LANDA）。



在所有特徵中，XGBoost認為比較重要的前五個特徵分別是區域、建物移轉總面積（坪）/租賃總面積（坪）（FAREA）、成交案件類型（CASE_T）、有無電梯（ELEVATOR）、單價是否含車位（UPNOTE）。

2. 特徵重要性分析

綜合 Linear Regression、DecisionTree 和 XGBoost 的分析結果，可以發現以下特徵在多種模型中都具有較高的重要性：

1. 建物移轉總面積 (坪) / 租賃總面積 (坪) (FAREA)

此特徵在所有模型中均被認為是關鍵變數，顯示出建物面積對於目標變數的預測有穩定且重要的影響，因為其直接反映了交易的規模。

2. 車位移轉總面積 (坪) / 車位租賃總面積 (坪) (PAREA)

此特徵在 Linear Regression 和 DecisionTree 中均為重要特徵，表明車位面積與交易的價值有一定關聯。

3. 成交案件類型 (CASE_T)

此特徵在 Linear Regression 和 XGBoost 中被認為重要，顯示交易類型對於結果的區分有顯著影響。

4. 有無電梯 (ELEVATOR)

此特徵在 DecisionTree 和 XGBoost 中均為重要特徵，反映建物中是否配備電梯可能對交易價格有明顯的影響。

5. 區域

此特徵在 DecisionTree 和 XGBoost 中被認為重要，說明地區性因素對交易結果的影響不容忽視。

3. 共通性較高的特徵結論

「建物移轉總面積 (坪) / 租賃總面積 (坪) (FAREA)」是所有模型中最一致的重要特徵，這是很明顯的，因為坪數越高房價當然越高。此外，「車位移轉總面積 (坪) / 車位租賃總面積 (坪) (PAREA)」和「成交案件類型 (租賃/預售買賣.....) (CASE_T)」也在多數模型中表現出色，反映這些變數對結果的解釋能力具有穩定性。至於「有無電梯 (ELEVATOR)」和「區域」也對房價很重要，因為便利性也是影響人們選擇房屋的重要因素。但值得一提的是，附近捷運站的數量似乎與房價關係不大，可能是因為台北的捷運站過於密集，所以可能要用其他更好的特徵來衡量生活機能，例如百貨公司。

六、結語

透過本次的分析，我們成功運用了機器學習模型對臺北市不動產數據進行價格預測，並深入探討了影響房價的關鍵因素。結果顯示，「建物移轉總面積（坪）」無疑是最具影響力的變數，其次是「車位移轉總面積」、「成交案件類型」、「有無電梯」及「區域」。這些特徵反映了房地產市場的核心價值指標，為買家、賣家和開發商提供了實用的參考依據。

本研究的改進方向則有以下。首先，房屋區位資料特徵的選取尚有優化空間，例如探索更多能反映生活機能、周遭便利性的指標，像是房屋內部條件、周邊公共設施、周邊百貨公司數量.....，來補足目前模型未能充分解釋的部分。其次，在特徵編碼與選擇上，應進一步測試不同方法對模型表現的影響，以提升預測精度和泛化能力。